

Pipeline de Inteligência Artificial: Treinamento e Inferência no Azure ML

Resumo executivo da arquitetura de Machine Learning para predição individualizada de absenteísmo, balanceamento via SMOTE sem data leakage e deploy REST.

1. O Desafio Clínico: Por que Estimar Probabilidade Contínua?

Classificadores binários tradicionais (que devolvem apenas 0 ou 1) são insuficientes na saúde. Um paciente com **48% de chance de falta** precisa de confirmação reforçada via WhatsApp, enquanto um com **85%** justifica a abertura de overbooking no horário. O pipeline da Vitta Care extrai a **probabilidade marginal contínua p_i** através de `predict_proba()[ : , 1]`.

 **Armadilha da Acurácia**

Como 80% a 85% dos pacientes comparecem, um modelo ingênuo que sempre preveja "comparecimento" já teria 85% de acurácia, mas detectaria zero faltas. Por isso, a métrica de torneio é estritamente a **ROC-AUC**.

 **SMOTE sem Data Leakage**

O SMOTE é executado dentro do `imblearn.pipeline.Pipeline` em cada uma das 5 dobras da validação cruzada. Amostras sintéticas nunca poluem o conjunto de teste/validação.

2. Engenharia de Atributos & Pré-Processamento Hermético

O modelo processa **18 variáveis** agregadas em três categorias pelo `ColumnTransformer` do `scikit-learn`:

- **5 Variáveis Numéricas Contínuas:** `dias_antecedencia`, `distancia_km`, `renda_media_bairro`, `numero_consultas_ult_30d`, `taxa_historica`. Tratadas com `SimpleImputer(strategy='median')` e `StandardScaler`.
- **4 Variáveis Binárias:** `lembrete_enviado`, `feriado_proximo`, `is_weekend`, `lembrete_hist`. Tratadas com `SimpleImputer(strategy='most_frequent')`.
- **9 Dummies Categóricas:** Faixas discretizadas de distância (perto/médio/longe), faixas de renda e turnos (Manhã/Tarde).
- **Seleção ANOVA:** `SelectKBest(score_func=f_classif, k='all')` acoplado no pipeline final.

3. Torneio de 4 Modelos sob Validação Cruzada Estratificada

Quatro famílias algorítmicas competem sob o mesmo protocolo estratificado de 5 dobras:


Modelo	Tratamento de Desbalanceamento	Vantagem Operacional
XGBoost Classifier	<code>scale_pos_weight = N_neg / N_pos</code>	Otimiza gradientes de perda com árvores profundas e regularização L1/L2
Random Forest	<code>class_weight='balanced'</code>	Bagging de árvores não correlacionadas; alta robustez contra ruído
Gradient Boosting	SMOTE integrado na dobra	Redução sequencial do erro residual via taxa de aprendizado controlada
Regressão Logística	<code>class_weight='balanced'</code> , solver <code>saga</code>	Benchmark linear rápido com interpretabilidade direta dos coeficientes

4. Empacotamento Hermético e Eliminação de Train-Serve Skew

O modelo campeão não é salvo isolado. Ele é serializado no `bundle_model.pkl` junto com o `ColumnTransformer` ajustado no treino e o `threshold` ótimo. Na inferência, os dados brutos passam exatamente pelos mesmos parâmetros de média e desvio padrão.

5. Fluxograma Operacional: Do Treinamento à Decisão de Overbooking

Visão completa do ciclo de vida: dados, MLOps no Azure, deploy ACI e consumo estocástico no Flutter.



6. Otimização do Limiar de Decisão por Kolmogorov-Smirnov

Em vez do corte arbitrário $t = 0.50$, o módulo de avaliação calcula o **limiar ótimo** que maximiza a separação entre as classes reais de falta e presença (Índice de Youden J):

$$t^* = \text{argmax} [\text{TPR}(t) - \text{FPR}(t)] = \text{argmax} [\text{KS}(t)]$$

TPR (Sensibilidade): Taxa de verdadeiros positivos capturados.

FPR (1 - Especificidade): Taxa de falsos alarmes tolerados.

7. Explicabilidade Clínica com SHAP (XAI)

Para atender às exigências de transparência clínica e ética, o pipeline integra o **SHAP** (SHapley Additive exPlanations), baseado na teoria dos jogos cooperativos. O TreeExplainer decompõe cada predição em:

$f(\mathbf{x}) = \varphi_0 + \sum \varphi_j(\mathbf{x})$ — onde φ_0 é o risco base médio e cada φ_j é o impacto marginal de uma feature específica (ex: "antecedência de 25 dias somou +18% ao risco; lembrete recebido subtrai -12%").

8. Consumo no Flutter e Simulação de Monte Carlo

- Denormalização:** O endpoint ACI escreve no Firestore em tb_agendamentos.probabilidade_falta.
- Ingestão Reativa:** O AppointmentService no Flutter mapeia o campo para pFaltaPrevista.
- Alimentação da Cópula:** As probabilidades individuais alimentam a Cópula Gaussiana em 20.000 iterações.
- Overbooking por Slot:** O algoritmo avalia cada médico × hora e autoriza encaixes orientados pelo pior caso.